

DocuMind Enterprise: Sistema Inteligente de Gestión y Análisis Documental

Fase 01: Analisis

Juan Esteban Rojas Melendez

Universitaria Tecnologica de Santander

Tabla de Contenidos

1. Descripción del Problema y Contexto Empresarial
2. Identificación de la Necesidad y Oportunidad de Negocio
3. Objetivos del Proyecto
4. Alcance y Exclusiones
5. Identificación de Actores y Perfil de Usuarios
6. Perfil de Usuarios / Personas
7. Requerimientos Funcionales (RF)
8. Requerimientos No Funcionales (RNF)
9. Reglas de Negocio (RN)
10. Historias de Usuario (con Criterios de Aceptación)
11. Casos de Uso (Especificación Resumida)
12. Priorización de Requisitos (Técnica MoSCoW)
13. Análisis y Matriz de Riesgos del Proyecto
14. Matriz de Trazabilidad Inicial

1. Descripción del Problema y Contexto Empresarial

En el contexto operativo corporativo, las organizaciones acumulan diariamente volúmenes significativos de documentación en soportes digitales heterogéneos, principalmente archivos en formatos PDF, DOCX y TXT. Esta información suele reposar en carpetas locales o compartidas sin estructura sistemática, configurando repositorios pasivos.

Dicha disposición genera problemas recurrentes: tiempos prolongados en la localización de datos específicos, saturación del personal administrativo en la lectura manual de expedientes, falta de categorización homogénea e imposibilidad de realizar consultas globales sobre el fondo documental. La carencia de mecanismos automáticos para convertir texto desestructurado en información procesable limita la capacidad de respuesta y eleva la tasa de error humano en la gestión de la información empresarial

2. Identificación de la Necesidad y Oportunidad de Negocio

- **Necesidad:** Transformar un repositorio pasivo de archivos dispersos en una plataforma centralizada que extraiga contenido automáticamente, clasifique expedientes, sintetice la información y permita consultas transversales directas.
- **Oportunidad de Negocio:** Implementar una solución empresarial apalancada en Modelos de Lenguaje Grande (LLM) y la arquitectura RAG (*Retrieval-Augmented Generation*) con base de datos vectorial. Esto permite reducir los costos y tiempos de auditoría documental, estandarizar la extracción de datos transaccionales (facturas, contratos y hojas de vida) y habilitar canales de consulta conversacionales fundamentados estrictamente en el acervo documental de la compañía.

3. Objetivos del Proyecto

- **Objetivo General:**

Diseñar, desarrollar, probar, documentar e implementar la solución empresarial web **DocuMind Enterprise**, orientada a gestionar repositorios de documentos y aplicar Inteligencia Artificial para transformar información no estructurada en información útil, consultable y estructurada para la empresa.

- **Objetivos Específicos:**

1. Implementar los módulos de autenticación y gestión documental para la carga, consulta, descarga y eliminación de archivos en formatos PDF, DOCX y TXT organizados en carpetas.
2. Construir una canalización de procesamiento mediante la API de Google Gemini (**gemini-3.6-flash**) que clasifique automáticamente los archivos en tres categorías, genere resúmenes ejecutivos y extraiga entidades en formato JSON.
3. Desarrollar un subsistema de indexación y búsqueda semántica con arquitectura RAG empleando representaciones vectoriales (**gemini-embedding-2**) y la extensión pgvector en PostgreSQL para resolver consultas en lenguaje natural.
4. Diseñar un tablero de control (*dashboard*) para la visualización de métricas de almacenamiento, distribución por tipologías y bitácora de trazabilidad de estados y errores de procesamiento.
5. Validar y verificar la integridad de la plataforma ejecutando planes de pruebas integrales sobre un corpus documental de prueba compuesto por al menos 30 documentos.

4. Alcance y Exclusiones

Alcance del Sistema:

- Control de acceso de usuarios mediante autenticación basada en tokens JWT.
- Administración de repositorios y carpetas para almacenamiento lógico de archivos.
- Gestión de archivos binarios admitiendo de forma exclusiva extensiones **.pdf**, **.docx** y **.txt**.
- Procesamiento con IA que incluye clasificación obligatoria en tres tipologías (*Facturas y Cuentas de Cobro, Contratos y Acuerdos Legales, Hojas de Vida / Perfiles Laborales*).
- Generación de resúmenes automáticos por documento mediante modelos LLM.
- Extracción estructurada en esquema JSON para campos específicos según la categoría identificada.
- Fragmentación de texto (*chunking*), generación de *embeddings* y búsqueda por similitud de coseno en **pgvector**.
- Módulo interactivo de preguntas y respuestas en lenguaje natural sobre los documentos procesados.
- Monitoreo centralizado mediante *dashboard* y gestión de estados (**Pendiente**, **Procesando**, **Procesado**, **Error**).

Exclusiones:

- No incluye procesamiento de imágenes escaneadas carentes de capa de texto mediante OCR avanzado; los archivos deben contener capas de texto legibles.
- No contempla la edición directa en línea del contenido interno de los archivos **.pdf** o **.docx**.

- No abarca esquemas de permisos jerárquicos multitenancy complejos a nivel de departamento; se manejará acceso autenticado estándar empresarial.

5. Identificación de Actores y Perfil de Usuarios

Actor	Rol/Perfil	Responsabilidades en DocuMind Enterprise
Gestor Documental	Operativo/Archivo	Iniciar sesión, crear carpetas organizacionales, cargar lotes de documentos y supervisar el avance de las tareas de procesamiento
Analista/Auditor	Negocio/Consultoría	Consultar los metadatos generados, revisar los resúmenes y datos JSON extraídos, descargar los archivos originales e interactuar con el módulo RAG para formular preguntas en lenguaje natural
Administrador del Sistema	Soporte/Tecnico	Supervisar los indicadores globales del repositorio en el <i>dashboard</i> , auditar el registro de fallos técnicos o errores de conexión con el proveedor de IA y verificar el estado del almacenamiento

6. Perfil de Usuarios / Personas

Persona 1: El Operador de Archivo

- **Nombre ficticio:** Carlos Mendoza (32 años).

- **Rol en la empresa:** Asistente de Operaciones y Archivo Central.
- **Nivel tecnológico:** Intermedio (manejo fluido de suites ofimáticas, correo y unidades en la nube).
- **Contexto y Objetivos:** Recibe a diario decenas de facturas y contratos en formatos mixtos; necesita una herramienta donde pueda arrastrar lotes de archivos, organizarlos en carpetas sin complicaciones y verificar de un vistazo qué documentos se procesaron sin fallos.
- **Frustraciones actuales:** Pierde horas renombrando archivos a mano y revisando página por página para saber a qué proveedor o cliente corresponden.
- **Relación con DocuMind Enterprise:** Requiere una interfaz de carga limpia con indicadores visuales claros del progreso y alertas inmediatas si un archivo no es válido.

Persona 2: La Auditora y Tomadora de Decisiones

- **Nombre ficticio:** Laura Gómez (41 años).
- **Rol en la empresa:** Líder de Auditoría y Cumplimiento Legal.
- **Nivel tecnológico:** Básico-Intermedio (orientada al uso funcional de software empresarial, no técnica).
- **Contexto y Objetivos:** Necesita auditar contratos vigentes, montos de facturas o perfiles profesionales en segundos para emitir dictámenes y resolver inquietudes de gerencia.
- **Frustraciones actuales:** Debe abrir contratos extensos de 15 páginas solo para encontrar una fecha de vencimiento o una cláusula de confidencialidad. Las

búsquedas tradicionales por nombre de archivo fallan cuando el nombre no coincide con el contenido.

- **Relación con DocuMind Enterprise:** Su función clave es el módulo RAG; desea escribir preguntas como "¿Cuáles contratos finalizan en diciembre?" y recibir la respuesta exacta junto con la referencia del documento original para corroborar.

Persona 3: El Administrador Técnico de TI

- **Nombre ficticio:** Andrés Vega (28 años).
- **Rol en la empresa:** Administrador de Infraestructura y Soporte de TI.
- **Nivel tecnológico:** Avanzado (desarrollo web, bases de datos y administración de servidores).
- **Contexto y Objetivos:** Garantizar que la plataforma opere de manera estable, que el almacenamiento en disco no colapse y que las llamadas al proveedor de IA no generen excepciones no controladas.
- **Frustraciones actuales:** Los usuarios suelen reportar que "el sistema se trabó" sin aportar detalles, lo que complica el diagnóstico de fallos en APIs externas o bases de datos.
- **Relación con DocuMind Enterprise:** Depende del panel de indicadores y de la bitácora de errores técnicos (error_log) para identificar rápidamente si un fallo se debe a un documento corrupto o a una interrupción de conectividad con la API externa

7. Requerimientos Funcionales (RF)

- **RF-01 (Autenticación de Usuarios):** La plataforma DocuMind Enterprise debe permitir el inicio de sesión mediante correo y credenciales cifradas generando un token seguro de sesión (JWT).
- **RF-02 (Cierre de Sesión):** La plataforma debe invalidar la sesión del usuario al solicitar el cierre de la misma.
- **RF-03 (Protección de Rutas):** La plataforma debe denegar el acceso a las operaciones y vistas del repositorio a cualquier petición no autenticada.
- **RF-04 (Administración de Carpetas):** La plataforma debe permitir crear, listar y eliminar carpetas para clasificar los archivos de la empresa.
- **RF-05 (Carga Multiformato):** La plataforma debe permitir la subida de archivos asegurando la admisión estricta de extensiones PDF, DOCX y TXT.
- **RF-06 (Consulta y Descarga):** La plataforma debe permitir listar los archivos almacenados en cada carpeta y descargarlos en su formato fuente.
- **RF-07 (Eliminación de Documentos):** La plataforma debe permitir eliminar un archivo, borrando de forma sincronizada el archivo físico, sus metadatos y sus fragmentos vectoriales.
- **RF-08 (Extracción de Texto Plano):** La plataforma debe extraer el contenido textual legible de cada archivo cargado según su tipo MIME.
- **RF-09 (Clasificación Automática):** La plataforma debe clasificar cada archivo procesado dentro de una de tres categorías: Facturas y Cuentas de Cobro, Contratos y Acuerdos Legales, o Hojas de Vida / Perfiles Laborales.
- **RF-10 (Resumen Automático):** La plataforma debe generar un resumen ejecutivo conciso del contenido textual de cada documento procesado.

- **RF-11 (Extracción para Facturas):** La plataforma debe extraer en formato JSON estructurado: número de comprobante, emisor, cliente, fechas y valor total a pagar.
- **RF-12 (Extracción para Contratos):** La plataforma debe extraer en formato JSON estructurado: tipología contractual, partes intervinientes, objeto del contrato, vigencia y valor económico pactado.
- **RF-13 (Extracción para Hojas de Vida):** La plataforma debe extraer en formato JSON estructurado: nombre del postulante, titulación o rol principal, tiempo estimado de experiencia, competencias técnicas y máximo nivel educativo.
- **RF-14 (Vectorización para RAG):** La plataforma debe dividir el texto en fragmentos (chunks), generar representaciones vectoriales mediante **gemini-embedding-2** (parametrizado a 768 dimensiones) e insertarlas en la base de datos vectorial.
- **RF-15 (Búsqueda Documental por Metadatos):** La plataforma debe permitir filtrar y encontrar documentos por nombre, categoría, fecha de carga o estado.
- **RF-16 (Consulta en Lenguaje Natural sobre Documentos):** La plataforma debe responder preguntas complejas formuladas en lenguaje natural recuperando los fragmentos documentales pertinentes mediante similitud de vectores y citando las fuentes empleadas.
- **RF-17 (Dashboard de Indicadores):** La plataforma debe mostrar métricas globales sobre cantidad total de documentos, distribución proporcional por categorías y conteo de estados de procesamiento.
- **RF-18 (Registro y Trazabilidad de Fallos):** La plataforma debe llevar la traza de los estados del archivo (Pendiente, Procesando, Procesado, Error) y registrar el mensaje descriptivo en caso de anomalía en la IA o extracción.

8. Requerimientos No Funcionales (RNF)

- **RNF-01 (Seguridad de Credenciales y Variables de Entorno):** Las claves de API de Google Gemini, datos de conexión a la base de datos y llaves de cifrado JWT deben mantenerse en variables de entorno del servidor sin publicarse en el control de versiones.
- **RNF-02 (Rendimiento en Ingesta Documental):** El tiempo de extracción de texto y consulta inicial con el modelo LLM no debe sobrepasar 15 segundos para documentos de hasta 10 páginas bajo condiciones de red estables.
- **RNF-03 (Tiempo de Respuesta en Motor RAG):** El proceso de cálculo de embedding de la consulta, recuperación de contexto en pgvector y síntesis de respuesta no debe exceder los 5 segundos.
- **RNF-04 (Validación de Tipos de Archivo):** El sistema backend debe validar la cabecera y extensión de los archivos garantizando el rechazo inmediato de formatos no soportados.
- **RNF-05 (Indexación Vectorial Eficiente):** La persistencia vectorial debe emplear índices de aproximación de vecinos cercanos (HNSW) en pgvector para mantener la eficiencia en búsquedas semánticas.
- **RNF-06 (Usabilidad y Diseño Adaptable):** La interfaz construida con React y Tailwind CSS debe proporcionar indicadores visuales de carga, estados y responsividad para terminales de escritorio.
- **RNF-07 (Reproducibilidad de Despliegue):** La solución debe acompañarse de scripts de inicialización de base de datos y archivos de configuración para permitir su puesta en marcha en ambientes locales o servidores.

9. Reglas de Negocio (RN)

- **RN-01 (Obligatoriedad de Autenticación):** Toda operación de carga, visualización, descarga, borrado o consulta RAG exige una sesión activa validada.
- **RN-02 (Restricción de Formatos):** Solo se admiten archivos en formato .pdf, .docx y .txt con un límite configurable de hasta 10 MB por archivo.
- **RN-03 (Clasificación Categórica Estricta):** Cada archivo exitosamente procesado debe asignarse exclusivamente a una de las tres tipologías autorizadas (Facturas, Contratos, Hojas de Vida).
- **RN-04 (Esquema de Extracción Según Tipología):** El motor de análisis aplicará el esquema JSON de extracción correspondiente a la categoría detectada en el paso de clasificación.
- **RN-05 (Secuencia de Transición de Estados):** El ciclo de vida del estado documental seguirá obligatoriamente la secuencia Pendiente -> Procesando -> Procesado; ante cualquier excepción técnica en la extracción o consumo de la API, el estado pasará a Error con su respectiva bitácora.
- **RN-06 (Integridad Referencial en Eliminación):** Al eliminar un documento, la base de datos debe suprimir en cascada sus metadatos, resúmenes y fragmentos vectoriales (chunks).
- **RN-07 (Protección de Datos Personales):** Ningún archivo que integre el repositorio de pruebas de 30 documentos debe contener datos personales reales sin consentimiento explícito.

10. Historias de Usuario (con Criterios de Aceptación)

HU-01: Autenticación Segura en DocuMind Enterprise

- **Enunciado:** Como usuario del sistema, quiero ingresar mediante correo electrónico y clave para acceder a las funciones del repositorio.
- **Criterios de Aceptación:**
 1. Al enviar credenciales válidas, el backend entrega un token JWT y se redirige a la vista del dashboard.
 2. Si las credenciales fallan, el sistema despliega un mensaje descriptivo sin exponer datos del servidor.
 3. El cierre de sesión purga el token local y redirige a la pantalla de login.

HU-02: Carga y Validación Documental

- **Enunciado:** Como gestor documental, quiero cargar archivos PDF, DOCX y TXT en carpetas para almacenar el acervo de la compañía.
- **Criterios de Aceptación:**
 1. Permite seleccionar y subir archivos únicamente con extensiones .pdf, .docx y .txt.
 2. El registro inicial se crea con estado Pendiente.
 3. El sistema notifica y rechaza cualquier archivo que no cumpla con los formatos o límites definidos.

HU-03: Procesamiento Automatizado con Inteligencia Artificial

- **Enunciado:** Como analista, quiero que el sistema procese el contenido del archivo con IA para obtener automáticamente la categoría y un resumen ejecutivo.

- **Criterios de Aceptación:**

1. El sistema extrae el texto plano y lo evalúa mediante gemini-3.6-flash.
2. Se asigna una de las tres categorías requeridas.
3. Se almacena un resumen claro de 2 a 4 oraciones.
4. El documento pasa a estado Procesado o Error según el resultado técnico.

HU-04: Extracción Estructurada de Información Clave

- **Enunciado:** Como auditor, quiero visualizar entidades clave extraídas en formato estructurado para revisar datos críticos sin abrir el documento íntegro.

- **Criterios de Aceptación:**

1. Para Facturas, extrae emisor, cliente, número, fecha y total.
2. Para Contratos, extrae partes, objeto, vigencia y valor.
3. Para Hojas de Vida, extrae postulante, rol, años de experiencia, competencias y formación.

HU-05: Consulta en Lenguaje Natural (RAG)

- **Enunciado:** Como tomador de decisiones, quiero realizar preguntas conversacionales sobre el repositorio para resolver dudas directas sustentadas en el texto.

- **Criterios de Aceptación:**

1. La consulta calcula su embedding y recupera los fragmentos semánticamente afines de pgvector.
2. El modelo genera una respuesta sustentada únicamente en dichos fragmentos e indica los documentos de soporte.

3. Si la información no existe en el repositorio, la IA declara explícitamente la ausencia de datos.

HU-06: Monitoreo Global y Registro de Fallos

- **Enunciado:** Como administrador, quiero inspeccionar el tablero de indicadores y los registros de error para verificar la disponibilidad y rendimiento del sistema.
- **Criterios de Aceptación:**
 1. El panel muestra el total de documentos y la distribución por categoría.
 2. Muestra los conteos de estados (Pendiente, Procesando, Procesado, Error).
 3. Proporciona acceso al detalle del error técnico para documentos en estado fallido.

11. Casos de Uso (Especificación Resumida)

- **CU-01: Autenticación de Usuario**
 - *Actor:* Gestor Documental / Analista / Administrador.
 - *Flujo Principal:* El usuario remite credenciales; el servidor las valida contra la tabla users, emite un JWT y permite el ingreso a la plataforma.
- **CU-02: Cargar y Procesar Documento**
 - *Actor:* Gestor Documental.
 - *Flujo Principal:* El usuario remite un archivo; el backend lo valida, almacena el binario en disco, extrae el texto plano, invoca a **gemini-3.6-flash** para clasificación... calcula vectores con **gemini-embedding-2**, persiste los registros en PostgreSQL/pgvector y actualiza el estado a Procesado.
- **CU-03: Consulta Documental mediante RAG**

- *Actor:* Analista / Gestor Documental.
- *Flujo Principal:* El usuario escribe una pregunta; el sistema la vectoriza, ejecuta la búsqueda semántica en pgvector, envía el contexto recuperado al LLM y muestra la respuesta sintetizada con las fuentes.
- **CU-04: Eliminar Archivo**
 - *Actor:* Gestor Documental / Administrador.
 - *Flujo Principal:* El usuario selecciona un documento y confirma su eliminación; el sistema remueve el archivo binario del disco y ejecuta un borrado en cascada sobre los metadatos y vectores asociados en la base de datos.

12. Priorización de Requisitos (Técnica MoSCoW)

- **Must Have (Obligatorio):** RF-01, RF-02, RF-03 (Acceso), RF-04 a RF-07 (CRUD de archivos), RF-08 a RF-13 (Extracción, Clasificación y Resúmenes con IA), RF-14 y RF-16 (Indexación Vectorial y Consultas RAG), RNF-01 (Seguridad), RNF-04 (Soporte multiformato).
- **Should Have (Importante):** RF-15 (Búsqueda por metadatos), RF-17 (Dashboard de métricas), RF-18 (Bitácora de errores y estados), RNF-02 y RNF-03 (Tiempos de respuesta).
- **Could Have (Deseable):** Filtros combinados adicionales en el cliente, exportación de resultados a formatos CSV o PDF, paginación extendida.
- **Won't Have (Fuera de Alcance):** Reconocimiento óptico de caracteres (OCR) para imágenes o PDFs escaneados, edición interactiva en línea de documentos binarios.

13. Análisis y Matriz de Riesgos del Proyecto

ID	Riesgo Identificado	Prob.	Impacto	Nivel	Estrategia de Mitigacion
R-01	Límite de peticiones por minuto (Rate limits) en la capa gratuita de Gemini API	Alta	Alto	Critico	Implementar procesamiento secuencial con pausas controladas (throttling) y reintentos con retraso exponencial en el backend.
R02	Archivos PDF estructurados como imagen sin capa de texto seleccionable	Media	Alto	Alto	Construir los 30 documentos de prueba garantizando texto digital nativo e incluir validación que descarte archivos con menos de 20 caracteres legibles.
R-03	Inconsistencias en las respuestas JSON estructuradas del LLM	Media	Medio	Medio	Forzar response_schema estricto en el SDK de Gemini y encapsular la lectura en

					bloques de validación tipada con valores por defecto.
R-04	Respuestas alucinadas o fuera del repositorio en las consultas del RAG	Media	Medio	Medio	Restringir el prompt del sistema ordenando ceñirse únicamente a los fragmentos devueltos por pgvector e indicar la carencia de datos cuando proceda
R-05	Filtración involuntaria de la clave de API en repositorios publicos	Media	Critico	Alto	Registrar el archivo .env en el .gitignore desde la inicialización de Git y cargar secretos exclusivamente en el entorno del servidor

14. Matriz de Trazabilidad Inicial

Objetivo Específico	Requisito Funcional	Historia de Usuario	Caso de Uso	Prioridad
OE-01: Gestión	RF-01, RF-02,	HU-01	CU-01	Must Have

y Acceso	RF-03			
OE-01: Gestión y Acceso	RF-04, RF-05, RF-06	HU-02	CU-02	Must Have
OE-01: Gestión y Acceso	RF-07	HU-02	CU-04	Must Have
OE-02: Pipeline de IA	RF-08, RF-09, RF-010	HU-03	CU-02	Must Have
OE-02: Pipeline de IA	RF-11, RF-12, RF-13	HU-04	CU-02	Must Have
OE-03: Motor RAG	RF-14	HU-05	CU-02	Must Have
OE-03: Motor RAG	RF-15, RF-16	HU-05	CU-03	Must/Should
OE-04: Dashboard y Logs	RF-17, RF-18	HU-06	CU-01, CU-02	Should Have